

Classificazione di oggetti astronomici: un approccio basato sul Machine Learning




Laurea in Ingegneria Elettronica e Informatica


Contesto scientifico



Universo osservabile



Stelle




Quasar




Galassie

Fotometria




Machine Learning supervisionato



Obiettivi


01 Photometric Classification (Star, Galaxy, Qsos)

- Analisi dei dati fotometrici
- Implementazione dei modelli di classificazione
- Ottimizzazione
- Confronto



02 Redshift Regression

- Suddivisione dei dati classificati
- Applicazione dei modelli per classes
- Analisi e confronto
- Limiti



Il dataset



Progetto che ha raccolto dati di numerosissimi oggetti astronomici in cinque bande fotometriche.



Bande fotometriche

u : ultravioletto



g : verde-azzurra

r : rossa

i : vicino infrarosso

z : infrarosso

Distribuzione delle feature



Notiamo uno **sbilanciamento tra le classi**



Fase di apprendimento più delicata!

Feature Engineering


Derivazione degli
indici di colore



aggiunta alle sole
magnitudini per migliorare la
classificazione

<i>Indici di colore</i>
u - g
g - r
r - i
i - z

Analisi delle **correlazioni** tra le feature




Pre-processing



Import del dataset

```
import pandas as pd
df = pd.read_csv("sdss_data_big.csv", header=1)
```



Suddivisione in train-validation-test

```
from sklearn.model_selection import train_test_split
X_train_val, X_test, y_train_val, y_test = train_test_split(X,
y_class, test_size=0.2, random_state=42)
X_train, X_val, y_train, y_val = train_test_split(X_train_val,
y_train_val, test_size=0.3, random_state=42)
```

Standardizzazione

```
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_val_scaled = scaler.transform(X_val)
X_test_scaled = scaler.transform(X_test)
```




$$x' = \frac{x - \mu}{\sigma}$$

SVM lineare

Utilizzata come **baseline**

```
from sklearn.svm import SVC  
  
model = SVC(kernel='linear', decision_function_shape='ovo',  
random_state=42)  
  
model.fit(X_train_scaled, y_train) #Training del modello  
y_val_pred = model.predict(X_val_scaled)  
y_test_pred = model.predict(X_test_scaled)
```




-
- Classi sbilanciate
 - Alta confusione

Validation-accuracy: 76.7%
Test-accuracy: 77.6%

- ↓
- Accuracy discreta
 - Scarse metriche per i QSO




La classe predominante è favorita, la minoritaria penalizzata. Approccio lineare inadatto.



SVM polinomiale

Trasformazione con **kernel non lineare**

```
model = SVC(kernel='poly', degree=3, C=1.0, gamma='scale', coef0=0.0,
decision_function_shape='ovo', random_state=42)
```



Validation-accuracy: 76.8%
Test-accuracy: 77.3%

- Minor confusione per i QSO
- Confusione generale ancora alta
- Accuracy non migliorata
- Metriche ancora non sufficienti



Ottimizza una specifica classe a discapito delle altre.
Non offre un vantaggio netto.





SVM radial basis function



Trasformazione con **kernel non lineare**

```
model = SVC(kernel='rbf', C=1.0, gamma='scale', decision_function_shape='ovo', random_state=42)
```



Validation-accuracy: 90.2%
Test-accuracy: 90%

- Buona accuracy
- Migliori risultati per tutte e tre le classi, leggermente inferiori per i QSO



Buon compromesso tra accuratezza complessiva e robustezza per classe. Tuttavia, c'è ancora margine di miglioramento.



Ottimizzazione 1



Eseguita con **Grid Search**

```
param_grid = [  
    {'kernel': ['linear'], 'C': [0.1, 1, 10, 100]},  
    {'kernel': ['rbf'], 'C': [0.1, 1, 10, 100], 'gamma': [1e-3, 1e-2, 0.1,  
1]},  
    {'kernel': ['poly'], 'C': [0.1, 1, 10], 'degree': [2, 3, 4], 'gamma':  
['scale', 'auto']},  
]  
  
model = SVC(decision_function_shape='ovo', random_state=42)  
grid_search = GridSearchCV(model, param_grid, cv=5, scoring='accuracy',  
verbose=2, n_jobs=-1)  
grid_search.fit(X_train_scaled, y_train)  
best_model = grid_search.best_estimator_  
best_params = grid_search.best_params_  
best_kernel = best_params['kernel']
```

Set di valori da
esplorare



- evita **underfitting** ed **overfitting**
- eseguita in modo **automatico**

→ Otteniamo il **miglior modello**
(kernel + iperparametri tarati)





Miglior kernel	Parametri ottimali
rbf	C: 10, gamma: 1

Ottimizzazione 2



Risultati ottenuti

Miglior kernel	Parametri ottimali
rbf	C: 10, gamma: 1



Validation-accuracy: 91.4%
Test-accuracy: 91.4%




Le metriche migliorano leggermente per i QSO, restando stabili per le altre classi. Impatto moderato, ma equilibrio e robustezza migliorati.

Random Forest 1



Modello basato su **alberi decisionali**

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import GridSearchCV
param_grid = {
    'n_estimators': [50, 100, 150, 200],
    'max_depth': [None, 50, 100, 150]
}
model = RandomForestClassifier(random_state=42)
grid_search = GridSearchCV(model, param_grid, cv=4, scoring='accuracy',
verbose=2, n_jobs=-1)
grid_search.fit(X_train_scaled, y_train)
best_model = grid_search.best_estimator_
best_params = grid_search.best_params_
```



Parametri ottimali




n_estimators: 200
max_depth: None

Altri parametri:

- min_samples_split
- max_features
- min_samples_leaf
- bootstrap

Random Forest 2

Risultati ottenuti




 **Performance metriche solide.**
Riesce a gestire in modo efficace le classi sbilanciate.

Confronto

Performance simili in termini
di accuratezza, ma...



Modello	Validation accuracy	Test accuracy	Tempo di training	Tempo di predizione
SVM RBF	91.38%	91.35%	9.10s	13.49s
Random Forest	91.42%	91.14%	21.23s	0.47s




Tempi differenti!




Redshift regression 1

Modus operandi




Applicazione modelli

Per le **stelle**




- Redshift nullo
- **Non c'è necessità di applicare algoritmi di regressione.**



Redshift regression 2

Per le **galassie**




Si nota una chiara
relazione crescente
tra le magnitudini e
redshift



Redshift regression 2

Per le galassie




Modello	RMSE (val)	RMSE (test)	MAE (val)	MAE (test)	R² (val)	R² (test)
Lineare	0.062	0.065	0.043	0.046	0.913	0.904
Polinomiale	0.062	0.065	0.043	0.046	0.913	0.904
Lasso	0.062	0.065	0.043	0.046	0.913	0.904
SVR (RBF)	0.057	0.059	0.039	0.040	0.927	0.917
Random Forest	0.053	0.056	0.031	0.033	0.935	0.926



I modelli lineari sono una buona alternativa, ma la massima precisione si ha con Random Forest Regressor.

Redshift regression 3

Per i **quasar**




Maggiore variabilità
nei dati fotometrici,
con relazioni più
complesse



Redshift regression 4

Per i quasar





Altri modelli ottengono risultati peggiori dei Support Vector Regressor. Difficile stimare il redshift fotometrico nei quasar.

Conclusioni



Importanza dell'**analisi**

Applicazioni per grandi
survey astronomiche



Approcci di **deep learning**



Grazie per l'attenzione



gaetano.improta1@studenti.unicampania.it